

LAPORAN KESIAPAN MONEV

Pengembangan Perangkat Mobile dengan Teknologi Depth Sensor untuk
Penghitungan dan Klasifikasi Tandan Kelapa Sawit Berbasis Deep Learning

Tanggal penyusunan: 15 September 2026

Monev dijadwalkan: Rabu, 23 September 2026, pukul 10.00–11.00 WITA

Penyaji: Bu Fatma (Dosen Ilmu Komputer)

Disusun oleh: Muhammad Zainal Muttaqin (Asisten Dosen)

Sumber data: Repositori project-expertise, komit terakhir per 15 September 2026

Daftar Isi

1. Ringkasan Eksekutif

Penelitian ini bertujuan mengembangkan perangkat mobile yang menggunakan sensor kedalaman (*depth sensor*) untuk menghitung dan mengklasifikasikan tandan buah segar (TBS) kelapa sawit secara otomatis dengan pendekatan *deep learning*. Inti sistem adalah model kecerdasan buatan yang menerima citra RGB dan data kedalaman dari empat sisi pohon, kemudian mendeteksi lokasi tandan, menggabungkan deteksi antarsisi agar tidak terjadi penghitungan ganda, menentukan tingkat kematangan (B1–B4), dan menghasilkan jumlah tandan per kelas.

Setelah menjalankan lebih dari 80 konfigurasi eksperimen yang terdokumentasi, proyek telah menghasilkan capaian berikut:

- **Deteksi lokasi tandan** yang cukup kuat: F1 fisik 0,84–0,85.
- **Klasifikasi kematangan** yang belum memenuhi target: akurasi 74,4% pada korpus RGB (target internal 75%) dan 81,6% pada korpus *depth*.
- **Pencacahan total** yang mendekati acuan: galat rata-rata 0,77–1,36 tandan per pohon.
- **Pencacahan per kelas** yang masih menyimpang besar: kelas B2 kurang terhitung hingga 41%, sementara B3 berlebih 17% pada korpus RGB.
- **Manfaat sensor kedalaman** yang belum konsisten: terbukti meningkatkan lokalisasi, tetapi redundan untuk klasifikasi kematangan.
- **Aplikasi mobile dan integrasi perangkat** yang belum terverifikasi dari repositori ini.

Dokumen ini menyajikan seluruh data secara lengkap dan transparan.

2. Apa Tujuan Penelitian Ini?

Judul penelitian menetapkan empat komponen utama yang harus terpenuhi:

No.	Komponen	Pertanyaan Kunci
1	Perangkat mobile	Apakah sudah tersedia perangkat yang dapat digunakan di lapangan?
2	Teknologi depth sensor	Apakah sensor kedalaman memberikan nilai tambah yang terukur?
3	Penghitungan tandan	Apakah sistem mampu menghitung jumlah tandan per pohon dengan akurat?
4	Klasifikasi kematangan	Apakah sistem mampu menentukan tingkat kematangan B1-B4 dengan tepat?

Keempat komponen di atas saling bergantung: perangkat mobile adalah wadah pengiriman, sensor kedalaman adalah modalitas tambahan, dan penghitungan serta klasifikasi adalah kemampuan inti yang bergantung pada kualitas model deep learning. Laporan ini berfokus pada komponen 2, 3, dan 4 karena ketiganya merupakan substansi ilmiah yang memerlukan pembuktian empiris.

3. Seberapa Jauh Penelitian Sudah Berjalan?

3.1 Komponen yang Sudah Selesai

Komponen	Bukti	Rujukan
Dataset berlabel — tiga korpus RGB dan RGB+D	953 pohon (18.540 kotak), 763 pohon depth, 1.716 gabungan (1.364 unik)	docs/DATASET.md
Tiga arsitektur detektor — YOLO26l, RT-DETR-L, RF-DETR-L	Dilatih resolusi 1.280 px, dievaluasi pada partisi uji terpisah	experiments/EKSPERIMEN.md
Ensemble WBF (Weighted Box Fusion)	AP50 lokalisasi: 0,8350 (953), 0,8764 (763)	metrics/recap.md
Pipeline empat sisi — penaut, deduplikasi, pencacahan	Beberapa metode penaut (Hungarian, GSP MILP, prior rotasi)	PROPOSAL-Pipeline.md
Reproyeksi data kedalaman	Kalibrasi Orbbec, intrinsik/ekstrinsik, Brown-Conrady	docs/NEW763_RGBD4_RESULTS.md
Evaluasi terkontrol RGB vs RGB+D	Protokol bootstrap berpasangan, seed tetap	results/
Artefak evaluasi terkunci uji	JSON metrik per pohon dengan CI 95%	results/remote_eval_2026-08-28/
Log eksperimen kronologis	Lebih dari 80 simpul (V2-E-001-048, PT-E-001-036, AF-E-001-016)	experiments/EKSPERIMEN.md

3.2 Komponen yang Belum Selesai atau Belum Terverifikasi

Komponen	Kondisi	Dampak
Aplikasi mobile	Arsitektur dirancang; implementasi belum ditemukan di repositori	Belum dapat didemonstrasikan
Pemeriksaan kualitas foto	Modul penolakan buram/kurang/keliru belum selesai	Kualitas masukan belum terjamin
Pengukuran latensi	Belum ada bukti pengukuran pada perangkat sasaran	Kelayakan waktu-nyata belum diketahui
Antarmuka pengguna	Rancangan ada; implementasi belum terverifikasi	Pengguna belum dapat berinteraksi
Panduan pengambilan empat sisi	Prosedur terdokumentasi; penerapan belum terverifikasi	Konsistensi di lapangan belum terjamin

4. Berapa Angka Kinerja Model Terbaik?

4.1 Model Deteksi Terbaik (Tugas per Citra)

Tugas	Metrik	RGB 953	Depth 763	Catatan
Lokalisasi tanpa kelas	AP50	0,8419	0,8783	WBF + re-ranker
Deteksi + klasifikasi	mAP50	0,6012	0,6711	RF-DETR-L

AP50 mengukur kemampuan menemukan lokasi tandan tanpa menilai kelasnya. mAP50 mengukur deteksi sekaligus klasifikasi B1–B4. Selisih keduanya menunjukkan model cukup baik menemukan lokasi, tetapi sering salah menentukan kelas.

4.2 Pipeline Lengkap Terbaik (Tugas per Pohon, Hasil Uji Terkunci)

Metrik	Penjelasan	RGB 953 (135 pohon)	Depth 763 (110 pohon)
F1 Fisik	Keseimbangan presisi dan daya tangkap	0,8387	0,8534
Presisi fisik	Proporsi prediksi yang memang ada	0,8444	0,8926
Daya tangkap fisik	Proporsi tandan acuan yang ditemukan	0,8331	0,8175
Akurasi klasifikasi	Ketepatan kelas tandan tercocokkan	74,42%	81,62%
Tandan dicocokkan	Denominator akurasi	1.118	457
Makro-F1 E2E	F1 rerata 4 kelas termasuk FN dan FP	0,6034	0,6519
MAE pencacahan	Galat rata-rata jumlah per pohon	1,363	0,773
Toleransi ± 1	Pohon dengan galat maks 1 tandan	63,70%	85,45%
Ketepatan total	Pohon dengan jumlah total tepat	27,41%	44,55%
Ketepatan vektor	Pohon dengan B1–B4 semuanya tepat	5,19%	27,27%

4.3 Selang Kepercayaan 95% Metrik Utama

Dihitung melalui simulasi bootstrap berpasangan sebanyak 2.000 ulangan (random seed 42):

Metrik	RGB 953	Depth 763
F1 fisik	0,8387 [0,8174; 0,8587]	0,8534 [0,8301; 0,8761]
Akurasi klasifikasi	0,7442 [0,7112; 0,7735]	0,8162 [0,7765; 0,8556]
Makro-F1 E2E	0,6034 [0,5655; 0,6382]	0,6519 [0,6046; 0,6918]
MAE cacah total	1,363 [1,163; 1,585]	0,773 [0,609; 0,945]
Toleransi ± 1	0,6370 [0,5556; 0,7185]	0,8545 [0,7818; 0,9182]

4.4 Bias Pencacahan per Kelas

RGB 953 — Partisi Uji, 135 Pohon (Penaut Hungarian Anchor A):

Kelas	Prediksi	Acuan	Bias	Bias Relatif
B1 (lewat matang)	104	113	-9	-7,96%
B2 (matang optimal)	145	246	-101	-41,06%
B3 (matang awal)	824	706	+118	+16,71%
B4 (mentah)	251	277	-26	-9,39%
Total	1.324	1.342	-18	-1,34%

Depth 763 — Partisi Uji, 110 Pohon (Penaut GSP MILP):

Kelas	Prediksi	Acuan	Bias	Bias Relatif
B1 (lewat matang)	67	94	-27	-28,72%
B2 (matang optimal)	227	199	+28	+14,07%
B3 (matang awal)	177	215	-38	-17,67%
B4 (mentah)	41	50	-9	-18,00%
Total	512	558	-46	-8,24%

Temuan penting: Jumlah total yang mendekati acuan (bias -1,34% pada RGB) menyembunyikan kesalahan komposisi. Pada RGB, tandan B2 kurang terhitung 41% sementara B3 berlebih 17% — keduanya nyaris saling mengimbangi pada jumlah total, tetapi distribusi kematangan yang dilaporkan tidak mencerminkan kondisi sebenarnya.

4.5 Kinerja Makro-F1 per Kelas (Ujung ke Ujung)

Kelas	RGB 953	Depth 763
B1	0,7465	0,7578
B2	0,4706	0,7230
B3	0,6850	0,7092
B4	0,5114	0,4176

Kelas B2 pada RGB (0,47) dan B4 pada kedua korpus (0,51 dan 0,42) merupakan titik terlemah. B2 adalah tandan matang optimal yang menjadi sasaran utama panen.

5. Di Mana Letak Kelemahan Utama?

5.1 Kelemahan Kinerja

Prioritas	Kelemahan	Angka Terukur	Dampak
1	Pencacahan per kelas tidak akurat	Vektor tepat 5,19–27,27%; bias B2 –41%	Distribusi tidak dapat diandalkan
2	Klasifikasi kematangan belum konsisten	Akurasi 74,42% (953) < target 75%	1 dari 4 tandan salah kelas
3	Makro-F1 E2E masih rendah	0,60–0,65	Gabungan kesalahan bertumpuk
4	Manfaat depth belum konsisten	Lokalisasi naik; klasifikasi tidak	Keunggulan menyeluruh belum terbukti

5.2 Kelemahan Metodologis

Aspek	Penjelasan
Pergeseran temporal	Korpus 953 (Mei) dan 352/763 (Juli) memiliki distribusi kematangan sangat berbeda akibat jeda 80 hari. Perbandingan 4-kelas lintas-dataset tidak valid.
Daya statistik terbatas	Partisi uji 352 hanya 410 kotak acuan; CI selebar $\pm 0,058$ membuat selisih kecil tak terbedakan dari derau.
Kebocoran partisi data	44 dari 55 pohon uji dataset 352 termuat di partisi latih 953; 87% beririsan.
Reproduksi sebagian	Beberapa bobot model hilang dan dilatih ulang (selisih $\sim 0,005$ mAP50); stacking DINOv2-Large selisih 5,2 pp.

5.3 Sumber Kehilangan Kinerja Terbesar

Analisis dekomposisi galat (V2-E-013) menunjukkan bahwa **44,5% kapasitas model tereduksi akibat kesalahan klasifikasi kelas ordinal**, bukan kegagalan melokalisasi tandan. Lokalisasi agnostik-kelas mencapai AP50 0,73–0,88, jauh di atas deteksi 4-kelas (0,45–0,67). Temuan ini mengarahkan upaya perbaikan ke peningkatan kemampuan klasifikasi kematangan.

6. Apakah Sensor Kedalaman Memberikan Manfaat?

6.1 Bukti Positif

Temuan	Angka	Rujukan
Lokalisasi meningkat dengan depth Sobel edge	AP50: 0,7636 vs 0,7358 (+0,0278)	V2-E-024
Pipeline depth menghasilkan F1 dan MAE lebih baik	F1: 0,8534 vs 0,8387; MAE: 0,773 vs 1,363	Profil uji terkunci
Late fusion RGB+D memberikan sinyal saling melengkapi	YOLO union-WBF: +0,038 mAP50 pada validasi	NEW763_RGBD4_RESU LTS.md

6.2 Bukti Negatif atau Belum Meyakinkan

Temuan	Angka	Rujukan
Early fusion 4-kanal tidak konsisten	Seluruh CI 95% melintasi nol	NEW763_RGBD4_RESU LTS.md
Kedalaman redundan untuk klasifikasi	$I(Y; D \mid \text{RGB}) \approx 0$	V2-E-016
Depth monokular merugikan pada 953	$\Delta -0,0476$, CI $[-0,0671; -0,0274]$	V2-E-029
Lima kanal mengencerkan sinyal	$\Delta -0,0504$, CI $[-0,1038; -0,0015]$	V2-E-030
Selisih lokalisasi belum signifikan 95%	CI $[-0,0121; +0,0648]$, $P(\Delta > 0) = 92,1\%$	bootstrap_lokalisasi.json

6.3 Kesimpulan Kontribusi Depth

Sensor kedalaman memberikan kontribusi yang **terukur tetapi terbatas**:

- **Membantu lokalisasi:** sinyal fisik depth menembus batas dataset. Namun, bukti ini belum signifikan pada tingkat kepercayaan 95%.
- **Tidak membantu klasifikasi:** fitur kedalaman redundan terhadap fitur visual RGB untuk menentukan kematangan.
- **Potensi late fusion:** kombinasi prediksi RGB dan RGB+D memberikan sinyal menjanjikan pada validasi, tetapi belum dikonfirmasi pada data uji baru.

7. Upaya Apa Saja yang Sudah Dilakukan?

7.1 Arsitektur dan Pelatihan Detektor

Pendekatan	Eksperimen	Hasil
Tiga keluarga detektor (YOLO, RT-DETR, RF-DETR)	V2-E-001	RF-DETR-L unggul mAP50
Resolusi 960 vs 1.280 px	AF-E-006	1.280 px lebih baik
Bank combined1716 (1.716 pohon)	V2-E-035-041	AP50 naik; tidak otomatis untuk semua model
Weighted WBF	V2-E-043	Sebagian mAP naik, F1 fisik turun
Deep-tail proposal + re-ranker	MAP_BOOST	AP50: 0,8350 → 0,8419

7.2 Representasi dan Fusi Kedalaman

Pendekatan	Eksperimen	Hasil
Invers mentah	V2-E-005	Tidak konsisten antarmodel
Gradien Sobel (edge)	V2-E-008, 010	Terbaik untuk lokalisasi
Dropout, clipped, valid mask	V2-E-009	Kalah dari edge
Mid-fusion cabang + gate	V2-E-009	Gagal: puncak 0,2087
Early fusion 4-kanal pada 763	V2-E-034	CI melintasi nol
Late fusion union-NMS dan WBF	Follow-up	Menjanjikan; WBF tidak universal
Depth monokular	V2-E-027-032	Dua kali kalah signifikan
Lima kanal (sensor + monokular)	V2-E-030	Kalah signifikan

7.3 Penautan Lintas-Sisi dan Deduplikasi

Pendekatan	Eksperimen	Hasil
Union-Find dan Hungarian awal	PT-E-002	F1 linker hanya 0,4282
Prior arah rotasi searah jarum jam	PT-E-008	F1: 0,40 → 0,65 (keberhasilan penting)
Re-ID embedding	PT-E-003	Bocor (AUC train 1,0; test 0,72)
GNN penautan	PT-E-017	F1 naik ke 0,38; belum cukup
Learned edge linker (65 fitur)	HANDOFF	AUC 0,95 pada validasi
Greedy strict + sweep	V2-E-043	F1 0,83-0,86 (dari test)
GSP MILP	V2-E-045	Kenaikan F1 fisik nyata
Rekonstruksi 3D kaku	PT-E-009-013	AUC 0,45-0,51 (setara acak); ditolak

7.4 Klasifikasi Kematangan

Pendekatan	Eksperimen	Hasil
Klasifikasi langsung dari detektor	V2-E-001	Akurasi kelas terbatas

Pendekatan	Eksperimen	Hasil
ConvNeXt-Tiny / crop classifier	PT-E-012, 014	Baik pada crop, tidak bertahan E2E
CORAL ordinal loss	PT-E-014	Runtuh ke 33,05%; CORN lebih baik (69,83%)
DINOv2-Large stacking	V2-E-046	Val 76,8%; reproduksi hanya 71,6%
Komposisi lintas-lapis	V2-E-047	Val 85,0% (depth); solver hilang
Head-aware ranking	Wave 2	Akurasi naik, F1 fisik turun
Kalibrasi kelas (scale_macro)	Wave 2	Kandidat terbaik VAL; CI melintasi nol
Augmentasi fotometrik	Ditolak	Tidak memberi perbaikan menyeluruh
Pembobotan kelas, focal/mixed loss	Ditolak	Tidak menyelesaikan konflik tujuan

7.5 Pencacahan dan Rekonsiliasi

Pendekatan	Eksperimen	Hasil
Jumlah pool mentah	PT-E-004	Macro-MAE 3,34; gagal telak
Ridge Regression + F_all	V2-E-045	MAE 1,36 (953), 0,77 (763)
Rekonsiliasi jumlah per kelas	PT-E-005-007	Memperbaiki bias; identitas belum sembuh
Count meta-ensemble	Wave 2	Matched naik; MAE/±1 turun
Regresor non-linear	Wave 2	CV train membaik; VAL memburuk

7.6 Rangkuman Eksplorasi

Penelitian ini telah menguji **3 keluarga detektor**, **6+ representasi kedalaman**, **8+ metode penautan**, **10+ pengklasifikasi**, dan **5+ pendekatan pencacahan**, dengan total lebih dari 2.800 baris evaluasi. Pendekatan yang gagal didokumentasikan sebagai studi ablasi dan kontrol negatif. Konflik inheren antara tujuan lokalisasi, identitas fisik, klasifikasi kelas, dan pencacahan menjadi hambatan fundamental.

8. Ceklist Kesiapan Monev

8.1 Komponen yang Tersedia untuk Disajikan


Status	Komponen	Keterangan
Tersedia	Dataset RGB dan Depth	Tiga korpus, partisi terdokumentasi
Tersedia	Tiga arsitektur detektor	YOLO26l, RT-DETR-L, RF-DETR-L
Tersedia	Ensembel WBF	AP50 lokalisasi 0,84–0,88
Tersedia	Pipeline empat sisi	Penaut, deduplikasi, pencacahan
Tersedia	Reproyeksi kedalaman	Kalibrasi Orbbec, distorsi
Tersedia	Perbandingan RGB vs RGB+D	Bootstrap berpasangan, terkontrol
Tersedia	Evaluasi terkunci uji	JSON terlacak, CI tersedia

8.2 Komponen yang Belum Memenuhi Target

Status	Komponen	Keterangan
Belum memenuhi	Akurasi klasifikasi $\geq 75\%$	74,4% pada 953; 81,6% pada 763
Belum memenuhi	Pencacahan per kelas akurat	Bias B2: -41%; vektor tepat 5-27%
Belum konsisten	Manfaat depth sensor	Lokalisasi naik; klasifikasi redundan
Belum terverifikasi	Aplikasi mobile	Belum ditemukan implementasi
Belum terverifikasi	Demonstrasi ujung ke ujung	Belum ada bukti sistem terintegrasi

9. Visualisasi Data Pendukung

Berikut adalah lima grafik pendukung yang merangkum data kinerja secara visual:



Gambar 2: Bias pencacahan per kelas B1–B4 pada kedua korpus

\\msb\... \\msb\... \\msb\... \\msb\... \\msb\...

Gambar 3: Perbandingan kinerja RGB vs Depth per tugas

Gambar 4: Ceklist kesiapan komponen monev

Gambar 5: Selang kepercayaan 95% metrik utama

10. Lampiran Teknis

10.1 Karakteristik Dataset

Parameter	SawitMVC-YOLO (953)	SawitMVC-Depth (763)	Combined1716
Jumlah pohon	953	763 (v2.0.0)	1.716 (1.364 unik)
Jumlah citra	3.992	~3.052	~6.864
Kotak anotasi	18.540	~5.000+	~23.000+
Resolusi	960×1.280 px	1.280×800 px	Campuran
Modalitas depth	Tidak tersedia	Orbbec Y16 (848×480, mm)	Sebagian
Tanggal akuisisi	30 Apr – 16 Mei 2026	28–29 Jul 2026	Gabungan
Partisi uji	141 pohon	110 pohon	1.052 citra

10.2 Karakteristik Visual Kelas Kematangan

Kelas	Tingkat Kematangan	Karakteristik Visual	Median (px)
B1	Lewat matang (siap panen)	Jingga kemerahan cerah	133
B2	Matang optimal (siap panen)	Oranye bersemburat ungu kehitaman	120
B3	Matang awal / mengkal	Ungu kemerahan kehitaman	107
B4	Mentah / muda	Hitam kehijauan pekat	93

10.3 Arsitektur Pipeline

4 foto terarah (searah jarum jam) → Pemeriksaan kualitas (belum selesai) → Deteksi: YOLO26l + RT-DETR-L + RF-DETR-L (1.280 px) → Fusi proposal: WBF agnostik-kelas (IoU 0,60) → Penautan lintas-sisi (Hungarian / GSP MILP) → Klasifikasi per tandan → Pencacahan: Ridge Regression → Laporan (belum selesai)

10.4 Rujukan Berkas Utama

Topik	Berkas
Rekap metrik	metrics/recap.md
Pipeline uji RGB 953	results/remote_eval_2026-08-28/gsp_artifacts/953/results_test_locked.json
Pipeline uji Depth 763	results/remote_eval_2026-08-28/gsp_artifacts/depth/results_test_locked.json
Log eksperimen	experiments/EKSPERIMEN.md
Handoff & riwayat	HANDOFF.md
Laporan akhir Vol. 2	docs/LAPORAN-AKHIR.md
Hasil RGB+D 4-kanal	docs/NEW763_RGBD4_RESULTS.md

Topik	Berkas
CI lokalisasi	results/bootstrap_lokalisasi.json
Arsitektur pipeline	PROPOSAL-Pipeline.md
Audit forensik	docs/AUDIT-FORENSIK-2026-09-06.md

Laporan ini disusun berdasarkan pembacaan menyeluruh terhadap repositori project-expertise per 15 September 2026. Seluruh angka merujuk langsung ke artefak JSON dan dokumen Markdown yang tercantum.