

# Leaderboard Hasil Eksperimen

Dokumen ini mengonsolidasi seluruh hasil evaluasi dari atlas metrik menjadi papan peringkat terpadu untuk setiap korpus data uji pada sistem.

## Daftar task dan metrik

| Kolom                                 | Arti                                                                | Satuan                                    | Metrik                         |
|---------------------------------------|---------------------------------------------------------------------|-------------------------------------------|--------------------------------|
| detection                             | temukan kotak tandan, tanpa kelas (= lokalisasi)                    | per citra                                 | AP50                           |
| detection + classification (gabungan) | kotak + label sekaligus, dari detektor one-stage                    | per citra                                 | mAP50 class-aware              |
| deduplication                         | tandan sama lintas 4 sisi, tanpa hitung ganda                       | per pohon                                 | F1 fisik                       |
| classification                        | ketepatan kelas pada tandan yang sudah tertaut benar                | per pohon                                 | akurasi matched-class          |
| counting                              | jumlah tandan per kelas B1–B4 di tingkat kohort (sasaran utama BBC) | per kohort (validation set atau test set) | bias per kelas dan macro-avg \ |

## Satu table leaderboard per dataset

- **combined1716:** leaderboard utama RGB, daya statistik terkuat.
- **763-depth:** RGB+D
- **953:** RGB

## 1. 953 (RGB)

### Leaderboard 953

| Metode/sistem                                                                               | detection     | det+class     | dedup         | classification | counting (diagnostik) | Status | ID Simpul |
|---------------------------------------------------------------------------------------------|---------------|---------------|---------------|----------------|-----------------------|--------|-----------|
| YOLO26l                                                                                     | —             | 0,5435        | —             | —              | —                     | uji    | V2-E-001  |
| YOLO26s 960 px                                                                              | 0,8057        | 0,5433        | —             | —              | —                     | uji    | AF-E-006  |
| YOLO26m 1.280 px                                                                            | 0,8104        | —             | —             | —              | —                     | uji    | AF-E-011  |
| RT-DETR-L                                                                                   | —             | 0,5781        | —             | —              | —                     | uji    | V2-E-001  |
| RF-DETR-L                                                                                   | —             | <b>0,6012</b> | —             | —              | —                     | uji    | V2-E-001  |
| WBF [YOLO+RT+RF]                                                                            | 0,8350        | 0,5861        | —             | —              | —                     | uji    | V2-E-042  |
| WBF + <i>re-ranker</i>                                                                      | <b>0,8419</b> | 0,5970        | —             | —              | —                     | uji    | MAP_BOOST |
| WBF[YOLO26l+RT-DETR-L+RF-DETR-L] + rotation-prior linker + Ridge counter                    | 0,8350        | 0,5861        | 0,8043        | 71,1%          | 1,393                 | uji    | V2-E-045  |
| WBF[YOLO26l+RT-DETR-L+RF-DETR-L] + greedy strict                                            | —             | —             | 0,8296        | —              | 1,644                 | uji    | V2-E-043  |
| WBF[YOLO26l+RT-DETR-L+RF-DETR-L] + Hungarian <i>Anchor A</i> + Ridge counter                | 0,8350        | 0,5861        | <b>0,8387</b> | <b>74,4%</b>   | 1,363                 | uji    | Wave-V2   |
| YOLO26m + penaut terlatih + Ridge (Pipeline Panen)                                          | 0,8104        | —             | 0,7619        | 71,6%          | 1,402                 | uji    | AF-E-012  |
| WBF[YOLO26l+RT-DETR-L+RF-DETR-L] + rotation-prior linker + Ridge counter                    | —             | —             | 0,8087        | 70,0%          | 1,253                 | val    | V2-E-045  |
| WBF[YOLO26l+RT-DETR-L+RF-DETR-L] + Hungarian <i>Anchor A</i> + Ridge counter                | —             | —             | 0,8232        | 75,4%          | <b>1,253</b>          | val    | Wave-V2   |
| WBF[YOLO26l+RT-DETR-L+RF-DETR-L] + Hungarian <i>Anchor A</i> + <i>stacking</i> DINOv2-Large | —             | —             | —             | <b>76,8%</b>   | —                     | val    | V2-E-046  |
| YOLO26m + penaut terlatih + Ridge (Pipeline Panen)                                          | —             | —             | 0,7586        | 71,7%          | 1,374                 | val    | AF-E-012  |
| Plafon lokalisasi sempurna ( <i>oracle</i> ) + ConvNeXt-Tiny / Ridge                        | —             | 0,6569        | —             | —              | 1,058                 | oracle | AF-E-005  |

*Sel kosong berarti not applicable.*

## Counting kohort per kelas (sasaran BBC)

Tabel ini memuat satu-satunya metrik penilaian akhir tugas *counting*, yaitu bias per kelas. Nilainya dihitung terpisah untuk tiap split (validasi dan uji) pada tiap dataset, dengan menjumlahkan seluruh pohon dalam split tersebut.

### Partisi Uji (Hungarian *Anchor A*, 135 Pohon)

| Kelas        | Total prediksi | Total acuan  | Bias absolut | Bias relatif  |
|--------------|----------------|--------------|--------------|---------------|
| B1           | 104            | 113          | -9           | -7,96%        |
| B2           | 145            | 246          | -101         | -41,06%       |
| B3           | 824            | 706          | +118         | +16,71%       |
| B4           | 251            | 277          | -26          | -9,39%        |
| <b>Total</b> | <b>1.324</b>   | <b>1.342</b> | <b>-18</b>   | <b>-1,34%</b> |

Makro-rerata nilai mutlak bias relatif (macro-avg  $||bias||$ ): **18,78%**

### Partisi Validasi (Hungarian *Anchor A*, 91 Pohon)

| Kelas        | Total prediksi | Total acuan | Bias absolut | Bias relatif  |
|--------------|----------------|-------------|--------------|---------------|
| B1           | 84             | 86          | -2           | -2,33%        |
| B2           | 112            | 186         | -74          | -39,78%       |
| B3           | 560            | 476         | +84          | +17,65%       |
| B4           | 186            | 188         | -2           | -1,06%        |
| <b>Total</b> | <b>942</b>     | <b>936</b>  | <b>+6</b>    | <b>+0,64%</b> |

Makro-rerata nilai mutlak bias relatif (macro-avg  $||bias||$ ): **15,21%**

## 2. 763-depth (RGB+D)

### Leaderboard 763-depth

| Metode/sistem                                                            | detection     | det+class     | dedup         | classification | counting (diagnostik) | Status | ID Simpul |
|--------------------------------------------------------------------------|---------------|---------------|---------------|----------------|-----------------------|--------|-----------|
| YOLO26l native                                                           | —             | 0,5163        | —             | —              | —                     | uji    | V2-E-034  |
| RT-DETR-L native                                                         | —             | 0,5580        | —             | —              | —                     | uji    | V2-E-034  |
| YOLO26l, bank combined1716                                               | —             | 0,5765        | —             | —              | —                     | uji    | V2-E-042  |
| RF-DETR-L native                                                         | 0,7951        | 0,6129        | —             | —              | —                     | uji    | V2-E-034  |
| RT-DETR-L, bank combined1716                                             | —             | 0,6309        | —             | —              | —                     | uji    | V2-E-042  |
| WBF + <i>re-ranker</i>                                                   | <b>0,8783</b> | 0,6552        | —             | —              | —                     | uji    | MAP_BOOST |
| WBF [YOLO26l+RT-DETR-L+RF-DETR-L], bank combined1716                     | 0,8764        | 0,6691        | —             | —              | —                     | uji    | V2-E-042  |
| RF-DETR-L, bank combined1716                                             | —             | <b>0,6711</b> | —             | —              | —                     | uji    | V2-E-042  |
| WBF[YOLO26l+RT-DETR-L+RF-DETR-L] + greedy strict                         | —             | —             | <b>0,8590</b> | —              | 0,818                 | uji    | V2-E-043  |
| WBF[YOLO26l+RT-DETR-L+RF-DETR-L] + rotation-prior linker + Ridge counter | —             | —             | 0,8069        | 80,3%          | 0,891                 | uji    | V2-E-045  |
| WBF[YOLO26l+RT-DETR-L+RF-DETR-L] + GSP MILP + Ridge counter (Wave-V2)    | 0,8764        | 0,6691        | 0,8534        | <b>81,6%</b>   | <b>0,773</b>          | uji    | Wave-V2   |
| WBF[YOLO26l+RT-DETR-L+RF-DETR-L] + rotation-prior linker + Ridge counter | —             | —             | 0,8257        | 83,6%          | <b>0,726</b>          | val    | V2-E-045  |
| WBF[YOLO26l+RT-DETR-L+RF-DETR-L] + GSP MILP + Ridge counter (Wave-V2)    | —             | —             | 0,8526        | 84,6%          | 0,932                 | val    | Wave-V2   |
| WBF[YOLO26l+RT-DETR-L+RF-DETR-L] + GSP MILP + komposisi lintas-lapis     | —             | —             | 0,8542        | <b>85,0%</b>   | 0,915                 | val    | V2-E-047  |

*Sel kosong berarti not applicable.*

### Counting kohort per kelas (sasaran BBC)

Tabel ini memuat satu-satunya metrik penilaian akhir tugas *counting*, yaitu bias per kelas. Nilainya dihitung terpisah untuk tiap split (validasi dan uji) pada tiap dataset, dengan menjumlahkan seluruh pohon dalam split tersebut.

#### Partisi Uji (GSP MILP, 110 Pohon)

| Kelas        | Total prediksi | Total acuan | Bias absolut | Bias relatif  |
|--------------|----------------|-------------|--------------|---------------|
| B1           | 67             | 94          | -27          | -28,72%       |
| B2           | 227            | 199         | +28          | +14,07%       |
| B3           | 177            | 215         | -38          | -17,67%       |
| B4           | 41             | 50          | -9           | -18,00%       |
| <b>Total</b> | <b>512</b>     | <b>558</b>  | <b>-46</b>   | <b>-8,24%</b> |

Makro-rerata nilai mutlak bias relatif (macro-avg  $\|bias\|$ ): **19,62%**

#### Partisi Validasi (GSP MILP, 117 Pohon)

| Kelas        | Total prediksi | Total acuan | Bias absolut | Bias relatif   |
|--------------|----------------|-------------|--------------|----------------|
| B1           | 66             | 96          | -30          | -31,25%        |
| B2           | 234            | 205         | +29          | +14,15%        |
| B3           | 176            | 216         | -40          | -18,52%        |
| B4           | 32             | 53          | -21          | -39,62%        |
| <b>Total</b> | <b>508</b>     | <b>570</b>  | <b>-62</b>   | <b>-10,88%</b> |

Makro-rerata nilai mutlak bias relatif (macro-avg  $\|bias\|$ ): **25,88%**

### 3. combined1716 (RGB)

Korpus gabungan berkapasitas terbesar (1.716 pohon, 1.052 citra uji) difungsikan sebagai bank data pelatihan modul detektor. Korpus ini tidak memiliki label nilai acuan kebenaran (*ground truth*) multi-sisi tingkat pohon, sehingga evaluasinya terfokus pada tugas deteksi citra (detection dan det+class).

#### Leaderboard combined1716

| Metode/sistem    | detection     | det+class     | dedup | classification | counting (diagnostik) | Status | ID Simpul |
|------------------|---------------|---------------|-------|----------------|-----------------------|--------|-----------|
| YOLO26l native   | —             | 0,5389        | —     | —              | —                     | uji    | V2-E-035  |
| WBF native       | <b>0,8104</b> | 0,5538        | —     | —              | —                     | uji    | V2-E-039  |
| RT-DETR-L native | —             | 0,5745        | —     | —              | —                     | uji    | V2-E-035  |
| RF-DETR-L native | 0,7850        | <b>0,5960</b> | —     | —              | —                     | uji    | V2-E-035  |

Sel kosong berarti not applicable.

### 4. Karakteristik Visual & Skala Kematangan Tandan Sawit (docs/DATASET.md §1)

| Kelas Kematangan | Tingkat Kematangan & Status Panen | Karakteristik Visual Dominan                             | Ukuran Kotak Median (Korpus 953) |
|------------------|-----------------------------------|----------------------------------------------------------|----------------------------------|
| B1               | Lewat matang (siap panen)         | Jingga kemerahan cerah, posisi lingkaran terbawah kanopi | 133 piksel                       |
| B2               | Matang optimal (siap panen)       | Oranye kemerahan bersemburat ungu kehitan                | 120 piksel                       |

| Kelas Ke-matangan | Tingkat Kematangan & Status Panen  | Karakteristik Visual Dominan                          | Ukuran Kotak Median (Korpus 953) |
|-------------------|------------------------------------|-------------------------------------------------------|----------------------------------|
| B3                | Matang awal (mengkal / belum siap) | Ungu kemerahan kehitaman                              | 107 piksel                       |
| B4                | Mentah (muda / belum siap)         | Hitam kehijauan pekat, tertanam rapat di sela pelepah | 93 piksel                        |

## 5. Estimasi Selang Kepercayaan 95% Profil Terkunci Uji

Dihitung melalui simulasi *bootstrap* berpasangan sebanyak 2.000 ulangan (*random seed* 42) pada seluruh metrik alur kerja:

| Metrik Evaluasi                 | Korpus 953: Hungarian <i>Anchor A</i> (135 pohon) | Korpus 763-depth: GSP MILP (110 pohon) |
|---------------------------------|---------------------------------------------------|----------------------------------------|
| <i>F1</i> fisik                 | 0,8387 [0,8174; 0,8587]                           | 0,8534 [0,8301; 0,8761]                |
| Akurasi <i>matched-class</i>    | 0,7442 [0,7112; 0,7735]                           | 0,8162 [0,7765; 0,8556]                |
| Makro- <i>F1</i> ujung ke ujung | 0,6034 [0,5655; 0,6382]                           | 0,6519 [0,6046; 0,6918]                |
| MAE cacah total                 | 1,363 [1,163; 1,585]                              | 0,773 [0,609; 0,945]                   |
| Akurasi toleransi cacah $\pm 1$ | 0,6370 [0,5556; 0,7185]                           | 0,8545 [0,7818; 0,9182]                |

## 6. Batasan Validitas dan Kaveat Audit

| Aspek Batasan / Kaveat                                   | Implikasi terhadap Pembacaan dan Interpretasi Data                                                                                                                                                                                                                                           | Sumber Rujukan              |
|----------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------|
| Ambiguitas Makro- <i>F1</i> (AF-E-012)                   | Terdapat dua nilai: 0,6692 (klaster terpasangkan) dan 0,5201 (ujung ke ujung). Hanya nilai 0,5201 yang setara dengan baseline 0,6034.                                                                                                                                                        | EVIDENCE.md                 |
| Pipeline Panen (AF-E-012, AF-E-013)                      | Menggunakan 132 pohon, detektor tunggal YOLO26m. Unggul pada estimasi B1 toleransi $\pm 1$ (0,970) dan akurasi ordinal (0,9946).                                                                                                                                                             | AF-E-012, AF-E-013          |
| Pelanggaran kendala fisik (AF-E-010)                     | Telah dikoreksi oleh AF-E-014: pada profil terkunci dengan $\max\_size \leq 3$ , tingkat pelanggaran adalah 0,00%.                                                                                                                                                                           | AF-E-014, AF-E-016          |
| Status eksperimen AF-E                                   | Eksperimen audit (AF-E) berfungsi sebagai diagnostik pelengkap, bukan pengganti angka acuan profil terkunci.                                                                                                                                                                                 | Atlas 07                    |
| Status gelombang validasi (V2-E-046, V2-E-047, V2-E-048) | Ketiganya dipilih pada partisi validasi tanpa menyentuh partisi uji, sehingga tidak menggantikan angka uji terkunci. V2-E-048 (pelatihan ulang <i>head</i> sadar-komposisi) tidak memberi kenaikan: makro- <i>F1</i> turun 0,6890 $\rightarrow$ 0,6850 dan disimpan sebagai kontrol negatif. | experiments/STATUS.md §8–10 |
| Kebocoran data ( <i>leakage</i> ) combined1716           | Irisan identitas pohon ( <i>tree_id</i> ) antar-partisi belum diaudit tuntas.                                                                                                                                                                                                                | ANALISIS_PIPELINES.md       |

## 7. Sumber Data dan Keterlacakan Artefak

| Rujukan Bagian                                                    | Berkas Artefak Sumber Data                                                                                                                   |
|-------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------|
| detection, det+class dedup, classification, counting (diagnostik) | combined1716, new763; detector_matrix.json, class_agnostic_metrics_audit_2026-09-03.json<br>pipeline_combined1716_generalization_locked.json |
| Gelombang validasi (V2-E-046, V2-E-047)                           | 953_large_stack_bias_val_bootstrap.json, depth_composition_aware_head_results_val.json                                                       |
| Counting kohort per kelas                                         | Diturunkan dari medan metrics.classification.confusion_prediction_rows pada artefak Wave-V2                                                  |

| Rujukan Bagian            | Berkas Artefak Sumber Data               |
|---------------------------|------------------------------------------|
| Analisis audit dan plafon | experiments/AUDIT-FORENSIK-2026-09-06.md |