

Leaderboard Hasil Eksperimen

Dokumen ini mengonsolidasi seluruh hasil evaluasi dari atlas metrik menjadi papan peringkat terpadu untuk setiap korpus data uji pada sistem.

Daftar task dan metrik

Kolom	Arti	Satuan	Metrik
detection	temukan kotak tandan, tanpa kelas (= lokalisasi)	per citra	AP50
detection + classification (gabungan)	kotak + label sekaligus, dari detektor one-stage	per citra	mAP50 class-aware
deduplication	tandan sama lintas 4 sisi, tanpa hitung ganda	per pohon	F1 fisik
classification	ketepatan kelas pada tandan yang sudah tertaut benar	per pohon	akurasi matched-class
counting	jumlah tandan per kelas B1–B4 di tingkat kohort (sasaran utama BBC)	per kohort (validation set atau test set)	bias per kelas dan macro-avg bias ; MAE cacah total per pohon

Satu table leaderboard per dataset

- **combined1716**: leaderboard utama RGB, daya statistik terkuat.
- **763-depth**: RGB+D
- **953**: RGB

1. 953 (RGB)

Leaderboard 953

Metode/sistem	detection	det+class	dedup	classification	avg bias	MAE	Status	ID Simpul
YOLO26l	0,7388	0,5435	—	—	—	—	uji	V2 - E - 001
YOLO26s 960 px	0,8057	0,5433	—	—	—	—	uji	AF - E - 006
YOLO26m 1.280 px	0,8104	—	—	—	—	—	uji	AF - E - 011
RT-DETR-L	0,7437	0,5781	—	—	—	—	uji	V2 - E - 001
RF-DETR-L	·	0,6012	—	—	—	—	uji	V2 - E - 001
WBF [YOLO+RT+RF]	0,8350	0,5861	—	—	—	—	uji	V2 - E - 042
WBF + <i>re-ranker</i>	0,8419	0,5970	—	—	—	—	uji	MAP_BOOST
WBF[YOLO26l+RT-DETR-L+RF-DETR-L] + rotation-prior linker + Ridge counter	0,8350	0,5861	0,8043	71,1%	16,82%	1,393	uji	V2 - E - 045
WBF[YOLO26l+RT-DETR-L+RF-DETR-L] + greedy strict	0,8350	0,5861	0,8296	—	20,96%	1,644	uji	V2 - E - 043
WBF[YOLO26l+RT-DETR-L+RF-DETR-L] + Hungarian <i>Anchor A</i> + Ridge counter	0,8350	0,5861	0,8387	74,4%	18,78%	1,363	uji	Wave-V2
YOLO26m + penaut terlatih + Ridge (Pipeline Panen)	0,8104	—	0,7619	71,6%	23,22%	1,402	uji	AF - E - 012
WBF[YOLO26l+RT-DETR-L+RF-DETR-L] + rotation-prior linker + Ridge counter	0,8313	0,5691	0,8087	70,0%	17,49%	1,253	val	V2 - E - 045
WBF[YOLO26l+RT-DETR-L+RF-DETR-L] + Hungarian <i>Anchor A</i> + Ridge counter	0,8313	0,5691	0,8232	75,4%	15,21%	1,253	val	Wave-V2
WBF[YOLO26l+RT-DETR-L+RF-DETR-L] + Hungarian <i>Anchor A</i> + <i>stacking</i> DINOv2-Large	0,8313	0,5691	0,8232	76,8%	·	1,253	val	V2 - E - 046
YOLO26m + penaut terlatih + Ridge (Pipeline Panen)	0,8125	—	0,7586	71,7%	25,65%	1,374	val	AF - E - 012
Plafon lokalisasi sempurna (<i>oracle</i>) + ConvNeXt-Tiny / Ridge	—	0,6569	—	—	—	1,058	oracle	AF - E - 005

Legenda sel: — = tidak berlaku bagi konfigurasi tersebut (detektor tanpa penaut tidak memiliki metrik tingkat pohon; korpus combined1716 tidak memiliki nilai acuan multi-sisi tingkat pohon). · = dapat dihitung dari dump prediksi yang tersimpan, tetapi belum pernah dievaluasi. Alasan spesifik tiap sel · yang masih tersisa dirinci per node di §6 Batasan Validitas dan Kaveat Audit.

Counting kohort per kelas (sasaran BBC)

Tabel ini memuat satu-satunya metrik penilaian akhir tugas *counting*, yaitu bias per kelas. Nilainya dihitung terpisah untuk tiap split (validasi dan uji) pada tiap dataset, dengan menjumlahkan seluruh pohon dalam split tersebut.

Partisi Uji (Hungarian *Anchor A*, 135 Pohon)

Kelas	Total prediksi	Total acuan	Bias absolut	Bias relatif
B1	104	113	-9	-7,96%
B2	145	246	-101	-41,06%
B3	824	706	+118	+16,71%
B4	251	277	-26	-9,39%
Total	1.324	1.342	-18	-1,34%

Makro-rerata nilai mutlak bias relatif (macro-avg $|bias|$): **18,78%**

Partisi Validasi (Hungarian *Anchor A*, 91 Pohon)

Kelas	Total prediksi	Total acuan	Bias absolut	Bias relatif
B1	84	86	-2	-2,33%
B2	112	186	-74	-39,78%
B3	560	476	+84	+17,65%
B4	186	188	-2	-1,06%
Total	942	936	+6	+0,64%

Makro-rerata nilai mutlak bias relatif (macro-avg $|bias|$): **15,21%**

2. 763-depth (RGB+D)**Leaderboard 763-depth**

Metode/sistem	detection	det+class	dedup	classification	avg $ bias $	MAE	Status	ID Simpul
YOLO26l native	0,7161	0,5163	—	—	—	—	uji	V2-E-034
RT-DETR-L native	0,7712	0,5580	—	—	—	—	uji	V2-E-034
YOLO26l, bank combined1716	0,7812	0,5765	—	—	—	—	uji	V2-E-042
RF-DETR-L native	0,7951	0,6129	—	—	—	—	uji	V2-E-034
RT-DETR-L, bank combined1716	0,8243	0,6309	—	—	—	—	uji	V2-E-042
WBF + <i>re-ranker</i>	0,8783	0,6552	—	—	—	—	uji	MAP_BOOST
WBF [YOLO26l+RT-DETR-L+RF-DETR-L], bank combined1716	0,8764	0,6691	—	—	—	—	uji	V2-E-042
RF-DETR-L, bank combined1716	0,8329	0,6711	—	—	—	—	uji	V2-E-042
WBF[YOLO26l+RT-DETR-L+RF-DETR-L] + greedy strict	0,8764	0,6691	0,8590	—	18,65%	0,818	uji	V2-E-043
WBF[YOLO26l+RT-DETR-L+RF-DETR-L] + rotation-prior linker + Ridge counter	0,8764	0,6691	0,8069	80,3%	13,93%	0,891	uji	V2-E-045
WBF[YOLO26l+RT-DETR-L+RF-DETR-L] + GSP MILP + Ridge counter (Wave-V2)	0,8764	0,6691	0,8534	81,6%	19,62%	0,773	uji	Wave-V2
WBF[YOLO26l+RT-DETR-L+RF-DETR-L] + rotation-prior linker + Ridge counter	0,8648	0,6595	0,8257	83,6%	14,10%	0,726	val	V2-E-045
WBF[YOLO26l+RT-DETR-L+RF-DETR-L] + GSP MILP + Ridge counter (Wave-V2)	0,8648	0,6595	0,8526	84,6%	25,88%	0,932	val	Wave-V2
WBF[YOLO26l+RT-DETR-L+RF-DETR-L] + GSP MILP + komposisi lintas-lapis	0,8648	0,6595	0,8542	85,0%	·	0,915	val	V2-E-047

Legenda sel: — = tidak berlaku bagi konfigurasi tersebut (detektor tanpa penaut tidak memiliki metrik tingkat pohon; korpus combined1716 tidak memiliki nilai acuan multi-sisi tingkat pohon). · = dapat dihitung dari dump prediksi yang tersimpan, tetapi belum pernah dievaluasi. Alasan spesifik tiap sel · yang masih tersisa dirinci per node di §6 Batasan Validitas dan Kaveat Audit.

Counting kohort per kelas (sasaran BBC)

Tabel ini memuat satu-satunya metrik penilaian akhir tugas *counting*, yaitu bias per kelas. Nilainya dihitung terpisah untuk tiap split (validasi dan uji) pada tiap dataset, dengan menjumlahkan seluruh pohon dalam split tersebut.

Partisi Uji (GSP MILP, 110 Pohon)

Kelas	Total prediksi	Total acuan	Bias absolut	Bias relatif
B1	67	94	-27	-28,72%
B2	227	199	+28	+14,07%
B3	177	215	-38	-17,67%
B4	41	50	-9	-18,00%
Total	512	558	-46	-8,24%

Makro-rerata nilai mutlak bias relatif (macro-avg |bias|): **19,62%**

Partisi Validasi (GSP MILP, 117 Pohon)

Kelas	Total prediksi	Total acuan	Bias absolut	Bias relatif
B1	66	96	-30	-31,25%
B2	234	205	+29	+14,15%
B3	176	216	-40	-18,52%
B4	32	53	-21	-39,62%
Total	508	570	-62	-10,88%

Makro-rerata nilai mutlak bias relatif (macro-avg |bias|): **25,88%**

3. combined1716 (RGB)

Korpus gabungan berkapasitas terbesar (1.716 pohon, 1.052 citra uji) difungsikan sebagai bank data pelatihan modul detektor. Korpus ini tidak memiliki label nilai acuan kebenaran (*ground truth*) multi-sisi tingkat pohon, sehingga evaluasinya terfokus pada tugas deteksi citra (detection dan det+class).

Leaderboard combined1716

Metode/sistem	detection	det+class	dedup	classification	avg bias	MAE	Status	ID Simpul
YOLO26l native	0,7250	0,5389	—	—	—	—	uji	V2 - E - 035
WBF native	0,8104	0,5538	—	—	—	—	uji	V2 - E - 039
RT-DETR-L native	0,7577	0,5745	—	—	—	—	uji	V2 - E - 035
RF-DETR-L native	0,7850	0,5960	—	—	—	—	uji	V2 - E - 035

Legenda sel: — = tidak berlaku bagi konfigurasi tersebut (detektor tanpa penaut tidak memiliki metrik tingkat pohon; korpus combined1716 tidak memiliki nilai acuan multi-sisi tingkat pohon). · = dapat dihitung dari dump prediksi yang tersimpan, tetapi belum pernah dievaluasi. Alasan spesifik tiap sel · yang masih tersisa dirinci per node di §6 Batasan Validitas dan Kaveat Audit.

4. Karakteristik Visual & Skala Kematangan Tandan Sawit (docs/DATASET.md §1)

Kelas Kematangan	Tingkat Kematangan & Status Panen	Karakteristik Visual Dominan	Ukuran Kotak Median (Korpus 953)
B1	Lewat matang (siap panen)	Jingga kemerahan cerah, posisi lingkaran terbawah kanopi	133 piksel
B2	Matang optimal (siap panen)	Oranye kemerahan bersemburat ungu kehitaman	120 piksel
B3	Matang awal (mengkal / belum siap)	Ungu kemerahan kehitaman	107 piksel

Kelas Ke-matangan	Tingkat Kematangan & Status Panen	Karakteristik Visual Dominan	Ukuran Kotak Median (Korpus 953)
B4	Mentah (muda / belum siap)	Hitam kehijauan pekat, tertanam rapat di sela pelepah	93 piksel

5. Estimasi Selang Kepercayaan 95% Profil Terkunci Uji

Dihitung melalui simulasi *bootstrap* berpasangan sebanyak 2.000 ulangan (*random seed* 42) pada seluruh metrik alur kerja:

Metrik Evaluasi	Korpus 953: Hungarian <i>Anchor A</i> (135 pohon)	Korpus 763-depth: GSP MILP (110 pohon)
<i>F1 fisik</i>	0,8387 [0,8174; 0,8587]	0,8534 [0,8301; 0,8761]
Akurasi <i>matched-class</i>	0,7442 [0,7112; 0,7735]	0,8162 [0,7765; 0,8556]
Makro- <i>F1</i> ujung ke ujung	0,6034 [0,5655; 0,6382]	0,6519 [0,6046; 0,6918]
MAE cacah total	1,363 [1,163; 1,585]	0,773 [0,609; 0,945]
Akurasi toleransi cacah ± 1	0,6370 [0,5556; 0,7185]	0,8545 [0,7818; 0,9182]

6. Batasan Validitas dan Kaveat Audit

Aspek Batasan / Kaveat	Implikasi terhadap Pembacaan dan Interpretasi Data	Sumber Rujukan
Ambiguitas Makro- <i>F1</i> (AF-E-012)	Terdapat dua nilai: 0,6692 (klaster terpasangkan) dan 0,5201 (ujung ke ujung). Hanya nilai 0,5201 yang setara dengan baseline 0,6034.	EVIDENCE.md
Pipeline Panen (AF-E-012, AF-E-013)	Menggunakan 132 pohon, detektor tunggal YOLO26m. Unggul pada estimasi B1 toleransi ± 1 (0,970) dan akurasi ordinal (0,9946).	AF-E-012, AF-E-013
Pelanggaran kendala fisik (AF-E-010)	Telah dikoreksi oleh AF-E-014: pada profil terkunci dengan $\max_size \leq 3$, tingkat pelanggaran adalah 0,00%.	AF-E-014, AF-E-016
Status eksperimen AF-E	Eksperimen audit (AF-E) berfungsi sebagai diagnostik pelengkap, bukan pengganti angka acuan profil terkunci.	Atlas 07
Status gelombang validasi (V2-E-046, V2-E-047, V2-E-048)	Ketiganya dipilih pada partisi validasi tanpa menyentuh partisi uji, sehingga tidak menggantikan angka uji terkunci. V2-E-048 (pelatihan ulang <i>head</i> sadar-komposisi) tidak memberi kenaikan: makro- <i>F1</i> turun 0,6890 $\rightarrow$ 0,6850 dan disimpan sebagai kontrol negatif.	experiments/STATUS.md §8–10
Kebocoran data (<i>leakage</i>) combined1716	Irisan identitas pohon (<i>tree_id</i>) antar-partisi belum diaudit tuntas.	ANALISIS_PIPELINE.md
Sel detection tak terisi, RF-DETR-L (V2-E-001, tabel 953)	Bobot <code>runs/rfdetr_1_e60_i1280_v2repro/</code> tidak ada di repositori maupun bucket cadangan Hugging Face; tidak ada dump prediksi tersimpan. Tidak dapat diisi tanpa pelatihan ulang 60 <i>epoch</i> penuh — belum dikerjakan sesi ini.	Audit sesi 2026-09-07
Sel detection RT-DETR-L (V2-E-001, tabel 953) terisi via retrain	Bobot <code>runs/rt detr_1_e60_i1280_v2repro/</code> asli juga hilang, sama seperti RF-DETR-L, tetapi dilatih ulang 60 <i>epoch</i> penuh sesi ini mengikuti protokol persis <code>experiments/EKSPERIMEN.md</code> V2-E-001 (<code>imgsz=1280, batch=4, seed=42, cos_lr=True, patience=60</code>). Reproduksi <code>det+class</code> mAP50=0,5718 vs. nilai asli 0,5781 (selisih 0,0063, dalam batas wajar variasi pelatihan ulang). Bobot baru diunggah ke bucket cadangan (<code>project-expertise/runs/rt detr_1_e60_i1280_v2repro_retrain/weights/best.pt</code>) agar tidak hilang lagi.	<code>rt detr_1_v2repro_953_retrain_2026-09-07.json</code>
Sel detection Pipeline Panen (AF-E-012, val, tabel 953) terisi setelah dua percobaan	Koreksi: klaim awal bahwa bobot detektor (<code>runs_panen/agnostik_m1280/</code>) dan classifier (<code>crops953/corn_best.pt</code>) tidak ada di bucket cadangan adalah keliru — keduanya ditemukan di bawah prefix <code>audit_forensik_2026-09-06/</code> . Percobaan pertama mengisi sel ini dari dump <code>dets.pkl</code> (ambang <code>conf=0,10</code> bawaan <code>detect()</code>) memberi AP50=0,7487 pada test, selisih 0,062 dari nilai detection AF-E-011/AF-E-012 yang sudah terpublikasi (0,8104, detektor identik) — terlalu besar untuk derau biasa, dibatalkan. Diinferensi ulang dengan <code>conf=0,001</code> (sebanding kolom detection lain): AP50= 0,8125 pada val, selisih hanya 0,002 dari nilai test 0,8104 — mengonfirmasi angka benar. Kolom <code>det+class</code> pada baris ini tetap – karena detektornya <code>class-agnostic</code> murni (setara baris uji), bukan sekadar belum dievaluasi.	<code>agnostic_ap50_panen_val_2026-09-07.json</code>

Aspek Batasan / Kaveat	Implikasi terhadap Pembacaan dan Interpretasi Data	Sumber Rujukan
Koreksi: detection/det+class baris val 953 (V2-E-045, wave-V2, V2-E-046) salah pada pengisian sesi 2026-09-07 sebelumnya	Dump prediksi bank combined1716 untuk partisi val 953 yang dipakai untuk mengisi sel ini sebelumnya (wbv_val_combined1716_2026-09-07.json) ternyata hanya memuat 263/404 citra val — seluruh 40 citra LONSUM_* dan 101 dari 364 citra DAMIMAS_* hilang (kemungkinan bug pemotongan pada inferensi sesi tersebut). Nilai lama 0,8373 / 0,5613 salah, dihitung dari ~65% data. Diinferensi ulang penuh (404/404 citra terverifikasi) dan dikoreksi menjadi 0,8313 / 0,5691. Partisi val 763-depth pada dump yang sama diperiksa dan terkonfirmasi lengkap (468/468) — tidak perlu koreksi. Ditemukan saat mengisi avg bias V2-E-045, karena F1 hasil rekonstruksi (0,69) jauh dari nilai dedup yang sudah dipublikasikan (0,8087), yang memicu audit lebih lanjut.	class_bias_v2e045_2026-09-07.json
Sel avg bias tak terisi (2 sel: V2-E-046, V2-E-047)	Formula (makro-rerata bias relatif B1–B4) diverifikasi persis terhadap keempat nilai Wave-V2 yang sudah terisi (dari medan gsp_best_by_class.metrics.classification.confusion_prediction_rows). V2-E-045 (4 sel, kedua korpus × uji/val) terisi sesi ini: model <i>count</i> Ridge di-fit pada partisi <i>train</i> via inferensi GPU baru tiga detektor bank combined1716 (koreksi bug di atas ditemukan dalam proses ini). Diagnosis sisa dua sel: V2-E-046 (953 val): harness.py menghitung confusion_prediction_rows secara internal tetapi large_stack.py membuangnya sebelum disimpan ke disk; regenerasi butuh fitur DINOv2-Large yang sudah diekstrak dan model <i>stacker</i>. joblib — keduanya dikonfirmasi tidak ada, baik di kontainer sesi ini maupun di bucket cadangan (diperiksa langsung). V2-E-047 (763-depth val): pola sama, composition_aware_head.py; cache fitur dan model .joblib-nya juga tidak ada di bucket. Pola umum: V2-E-043, V2-E-045, dan AF-E-012 berhasil diisi karena artefak sumbernya (dump proposal box, atau bobot detektor+classifier) ternyata tersimpan di results/ Git atau bucket cadangan. V2-E-046/V2-E-047 benar-benar berbeda: cache fitur dan model perantaranya memang tidak pernah dibackup sama sekali. Baris oracle AF-E-005 dikoreksi dari . menjadi -: studi ini murni plafon klasifikasi per-crop, tanpa tahapan penautan/pencacahan tingkat pohon, sejalan dengan kolom dedup/classification yang sudah -. V2-E-043 (kedua korpus, uji): medan confusion_matrix ditambahkan ke multiview_metrics() (scripts/eval_remote_pipeline_postprocess.py), F1 dan total acuan tervalidasi presisi penuh terhadap nilai dedup terpublikasi (0,8296 dan 0,8590). AF-E-012 (kedua split): bobot ditemukan di bucket (audit_forensik_2026-09-06/), pipeline diregenerasi penuh, F1/class4_acc cocok dalam <0,005. V2-E-045 (4 sel): medan confusion_matrix ditambahkan ke evaluate_payload() (scripts/evaluate_remote_count_reconciled.py), F1/class4_acc hasil rekonstruksi cocok dalam <0,004 dari nilai terpublikasi di keempat sel (satu cocok presisi penuh).	Audit sesi 2026-09-07

7. Sumber Data dan Keterlacakan Artefak

Rujukan Bagian	Berkas Artefak Sumber Data
detection, det+class	combined1716, new763; detector_matrix.json, class_agnostic_metrics_audit_2026-09-03.json, agnostic_ap50_sesi2026-08.json
dedup, classification	pipeline_combined1716_generalization_locked.json
Gelombang validasi (V2-E-046, V2-E-047)	953_large_stack_bias_val_bootstrap.json, depth_composition_aware_head_results_val.json
Counting kohort per kelas	Diturunkan dari medan metrics.classification.confusion_prediction_rows pada artefak Wave-V2
Analisis audit dan plafon	experiments/AUDIT-FORENSIK-2026-09-06.md
detection bank combined1716 uji, 763-depth (baris YOLO26l/RT-DETR-L/RF-DETR-L)	Dihitung ulang dari dump prediksi tersimpan (results/remote_eval_2026-08-27/predictions/) terhadap GT ULM-DS-Lab/SawitMVC-Depth-YOLO (test); lihat agnostic_ap50_combined1716_depth_test_2026-09-07.json
detection YOLO26l uji, 953 (V2-E-001)	Inferensi baru bobot lokal models/yolo26l_e60_i1280_v2repro/best.pt terhadap GT ULM-DS-Lab/SawitMVC-YOLO (test); lihat agnostic_ap50_v2repro_953_2026-09-07.json

Rujukan Bagian	Berkas Artefak Sumber Data
detection/det+class gelombang validasi (V2-E-045, Wave-V2, V2-E-046, V2-E-047)	Inferensi baru tiga bobot bank combined1716 pada partisi validasi kedua korpus, difusi WBF (protokol identik results/remote_eval_2026-08-27/README.md §1); lihat wbf_val_combined1716_2026-09-07.json
avg bias uji, V2-E-043 (kedua korpus)	Dihitung dari medan confusion_matrix baru pada multiview_metrics() (scripts/eval_remote_pipeline_postprocess.py), dijalankan pada proposal WBF uji tersimpan dengan hiperparameter dari pipeline_combined1716_greedy_test_tuned.json; lihat class_bias_v2e043_953_uji_2026-09-07.json, class_bias_v2e043_depth_uji_2026-09-07.json
detection RT-DETR-L uji, 953 (V2-E-001)	Retrain 60 <i>epoch</i> penuh (bobot asli hilang), inferensi pada test split; lihat rtdetr_1_v2repro_953_retrain_2026-09-07.json, dump pred_rtdetr_1_v2repro_953_test.npz
avg bias uji+val, AF-E-012 (953)	Pipeline Panen diregenerasi penuh (bobot ditemukan di bucket cadangan audit_forensik_2026-09-06/) via scripts/audit_forensik/panen_pipeline.py → panen_eval.py → panen_final.py, medan pred_class4_counts/gt_class4_counts baru ditambahkan ke evaluate(); lihat class_bias_afe012_953_2026-09-07.json
avg bias V2-E-045 (kedua korpus × uji/val); koreksi detection/det+class val 953	Inferensi GPU baru tiga detektor bank combined1716 pada partisi <i>train</i> kedua korpus, model <i>count</i> Ridge di-fit via scripts/evaluate_remote_count_reconciled.py (medan confusion_matrix baru ditambahkan); proses ini menemukan dan memperbaiki bug cakupan citra pada dump val 953 sesi sebelumnya; lihat class_bias_v2e045_2026-09-07.json